视频数据分析报告

20261017-《「实测」越贵的AI越菜？我对各大AI工具进行了测试...》分析总结

这是一次结构相当完整的自媒体横评：**20 道题、6 个 Agent、正确率／成本／耗时三维度**。结论「越贵越菜」**只在一半成立**——「档位溢价」成立，「产品定价」不成立，因为 Kimi 与 DeepSeek 的「贵」是计费方式折算出来的，不是真花了那么多钱。全片最大的方法论漏洞是成本口径跨产品不可比；评论区最有价值的也不是「谁最强」，而是**「你测的是模型还是 harness」**。

BV11fJX6GEcL　UP 主 **Zhan |**　发布 2026-10-16 17:00　时长 7:41
抓取 2026-10-17 19:48（发布后约 27 小时）　评论样本 150 / 全站 889

视频类型

技术·工具横评（A 型），带一点财经式的成本账

主题

用自制 20 题试卷，横评 6 个 AI Agent 的日常办公能力

最核心主张

贵的不一定强；Agent 的「高级模式」常常只是更贵

说得对不对

部分成立：档位倒挂有硬证据，产品定价的「贵」被口径放大

能解决什么问题

选型的初筛：日常办公场景该把预算给谁、该不该开高级模式

成熟度

可用（实验设计够用，成本口径需重做）

数据侧写

赞／币 4.74 : 1；评论／点赞 12.4%；收藏／点赞 67.7%

数据可靠性

发布仅 27 小时，各项计数仍在爬升，**绝对值不可引用**

视频本身价值

■■■□□ 3 / 5 · 表格可用，口径待修

评论区价值

■■■■□ 4 / 5 · 唯一指出 harness 混淆的地方

一句话

把它当中文互联网里少见的「愿意报数字」的横评来读，别当结论用——**它的证据比它的标题扎实得多。**

01

视频概览与定性

先看这份数据的可靠边界，再看它讲了什么

1.1 数据侧写：这是一个「值得存档」的视频，不是一个「值得争论」的视频

四个比值先摆出来，它们比任何观感都更能说明这条视频的性质。 我推断

指标	数值	怎么读
赞／币比	7,180 / 1,516 = **4.74 : 1**	介于「正经技术内容」（1.35 : 1）和「情绪段子」（≥20 : 1）之间。观众认为有留存价值，但不至于愿意为之付费。
收藏／点赞	4,860 / 7,180 = **67.7%**	本片最有信息量的一个数。**三分之二点赞的人同时点了收藏**——观众在存那张榜，不是在表态。这个比例远高于普通评论型内容。

指标	数值	怎么读
评论／点赞	889 / 7,180 = **12.4%**	越过 10% 线，评论区是第二战场。取样因此放大到 150 条。
投币率	1,516 / 142,389 = **1.06%**	偏低的付费意愿。与 4.74 的赞币比互相印证：工具类横评很难让人「感动到投币」。

> **数据还在爬升期。**视频发布于 2026-10-16 17:00，本报告抓取于 2026-10-17 19:48，**距发布仅 27 小时**。上表所有绝对值（播放、点赞、硬币、评论）都会在两三天内明显变化，**只有比值方向可信，数字不可引用**。

1.2 主题、主张与它的三个隐含前提

视频要回答的问题很直白：六个主流 AI Agent，谁最适合日常学习办公。 视频说 00:00

它实际给出的主张有两条，分量并不相同：

主张	它拿出的证据	隐含前提
A. 贵的 AI 不一定强	Kimi（¥24.63）第 4、DeepSeek（¥20.84）第 6；Codex（¥2.26）第 1、WorkBuddy（¥0.97）第 2	各家报的「元」是同一把尺子。这一条**不成立**，见第六部分。
B. 高级模式常常只是更贵	WorkBuddy 快速 87.37 分／¥0.97，极致+MAX 80.68 分／¥28.66；豆包同向	两组用的是同一套题、同一时间窗。这一条**成立且干净**，是本片最硬的证据。

还有三个没写在片子里的前提，读者需要自己补上：其一，20 道题能代表「日常办公」（片子自己在 07:06 承认了题量不足）；其二，跨产品的「元」可比；其三，各家默认档就是公平起点。 我推断

1.3 逐项判定

视频的说法	证据（片内可核对）	判定
Agent 高级模式不一定更好用，有时只是更贵	WorkBuddy 成本 ×29.5、分数 −6.69；豆包成本 ×21.2、分数 −3.79	基本可信 两组同向，且题目分开统计
最贵的两个排在最后	Kimi ¥24.63 第 4；DeepSeek ¥20.84 第 6	要收紧 「元」是积分／额度折算，非实际支出
表格任务随便找个 AI 都能干	3 道表格题，6 家除豆包一处 3.92 外全是满分	基本可信
数据分析题只有 Codex 三题全对	陷阱题（123 条 + 21 条空白 = 144 条）只有 Codex、豆包、千问答对	基本可信
做 PPT 各家表现都很接近	6 家均 8–9 页，都犯「没按需求重述总成本」的同类错误	基本可信
网页能力千问与 DeepSeek 更好	千问 9.26（34.7 分钟）、DeepSeek 9.11（¥1.12）	要收紧 一个靠时间堆、一个靠钱堆，不是同一维度的好
榜单「满分 100 分」	脚注写「办公题满分 73.5、代码题满分 23.5」，合计 **97**	被推翻 实际可得分上限是 97，不是 100
本期视频无任何商业推广	简介与片头均声明；评论区有「盲猜是 workbuddy 商单」	无法核实 无证据表明是商单，也无证据排除

1.4 分人群的价值

要选工具的人：这张榜能当第一道筛子，尤其「表格三题全部接近满分」这个结论可以直接省掉你很多试错。**要抄配置的人**：会失望——片子里「Codex 开到 Ultra 就能解决一切」是唯一给出的配置建议，它同时意味着成本失控。**要做评测的人**：值得逐帧看它的题目设计和分值分布，尤其那道「144 条规则」的陷阱题，是整片设计水平最高的一处。 我推断

02

视频核心总结

绪论立靶、本论三层证据、结论让步，以及链条断在哪

2.1 绪论：先把「严谨」这件事自我定价

片子的开场做了一件少见的事：**主动给自己的严谨度定档**——「从 6 个全球知名的 bench 精选 20 道由易到难的题」，并声明「比学术界不足，比自媒体界有余」，随后补一句「如果你说你的视频比我更严谨，那么无须争辩，我将直接认同」。**视频说** 00:37 01:05

这句话在传播上是加分项（先认怂，后手就没人挑），在方法论上是减分项——它把「够不够严谨」变成了不可讨论的话题。评论区最尖锐的那批人，恰恰是从这里开始不买账的。

2.2 本论：三层证据，一层比一层硬

第一层·总榜。六个 Agent 的分数咬得很紧：第 1 到第 5 名只差 14.36 分，其中第 4、第 5 名（78.60 与 78.20）几乎同分。真正拉开档次的是第 6 名 DeepSeek——73.70，且只过关 12/20。**视频说** 01:05

#	AGENT	过关	办公分	代码分	总分	成本	每元得分
1	Codex（OpenAI）	17 / 20	73.93	18.63	**92.56**	¥2.26	40.96
2	WorkBuddy 快速（腾讯）	16 / 20	68.69	18.68	**87.37**	¥0.97	**90.07**
3	豆包工作（字节跳动）	16 / 20	65.81	16.33	**82.14**	¥1.50	54.76
4	Kimi Work（月之暗面）	16 / 20	61.68	16.92	**78.60**	¥24.63	3.19
5	千问办公（阿里巴巴）	16 / 20	58.94	19.26	**78.20**	¥1.41	55.46

#	AGENT	过关	办公分	代码分	总分	成本	每元得分
6	DeepSeek（深度求索）	12 / 20	54.59	19.11	**73.70**	¥20.84	3.54

注意最后一列：「每元得分」的跨度是 28 倍（90.07 对 3.19）。这个数是我用视频自己的成本列算的，不是它给的（见第五部分）。 我推断

第二层·档位对照。这是全片最硬的一段。同一个产品、同一套题，只换档位，分数反而下降：

档位	过关	总分	成本	成本倍数	分数变化
WorkBuddy 快速	16 / 20	87.37	¥0.97	1.0×	基准
WorkBuddy 极致+MAX	15 / 20	80.68	¥28.66	**29.5×**	−6.69
豆包工作 自动（前 8 题）	7 / 8	26.08	¥0.66	1.0×	基准
豆包工作 2.1 Pro（前 8 题）	5 / 8	22.29	¥13.99	**21.2×**	−3.79

片方给出的机制解释也具体：差异「主要来自一道检索题」——那道要求跨年份、跨法条定位的多跳题，快速模式想 22 分钟答对，极致模式想 36 分钟答错。豆包 2.1 Pro 更直接：**8 道题就把一周额度用完了**，所以只能对比前 8 题。 视频说 01:59 02:28

第三层·分项能力。这一层暴露了总分榜掩盖的东西。

能力	题量	结果	解读
表格	3	6 家几乎全部满分；唯一失分是豆包考勤题 3.92／4	已商品化，不值得为它付溢价
数据分析	3	只有 Codex 三题全对；陷阱题仅 Codex、豆包、千问答对	真正的分水岭

能力	题量	结果	解读
PPT	1	均 8–9 页，图表清晰；都有排版与「未按需求重述总成本」的小错	差距在细节，不在能力
检索	2	除那道法律多跳题外，全部答对	常规检索已不成问题
网页	3	千问 9.26 → 豆包 6.33；豆包上传 Excel 直接解析失败	拉开 2.93 分，但代价是 34.7 分钟

2.3 结论：一句真正有价值的让步，被放在最后 30 秒

片子结尾主动认了三件事：题目总量少、不能绝对还原真实能力、主实验只测默认模式，未来应加入「同 Agent 不同模型」「同模型不同 Agent」以及多模态赛道。**视频说** 07:06

这段话的分量被放在片尾严重低估了——它其实自己指出了全片的结构性问题：**这次测的对象是「Agent 产品」，不是「模型」**。而标题卖的是「AI」。

2.4 链条断在哪四处

断点	具体表现	后果
成本不可比	网页排名表里，「花费」列混用积分（46.8／13.0）、额度百分比（4.23% 月额度）、按量（¥1.12）、点数（5 点 5 小时额度）	再折算成「元」放进同一列，跨产品结论失效
模型与 harness 混在一起	六个被测对象是「模型 + 外围工程」的组合，且组合方式不对等	「谁强」无法归因到模型，也无法归因到产品
「满分 100」不成立	办公 73.5 + 代码 23.5 = 97	所有分数实际是在 97 分制下的百分比，标题口径错 3 分
一次实验定生死	供应商降智、服务器波动都未控制；DeepSeek 单题就跑了 43 分钟	单次结果对「今天能不能用」敏感，对「能力上限」不敏感

03

评论区概览与总结

889 条里取热度前 150 条，聚成 7 簇

3.1 结构侧写

取样：热度排序前 150 条（含楼中楼），占全站 889 条的 16.9%；其中顶层评论 88 条、楼中楼 62 条。剔除纯表情、无关、引流后，**有效样本 58 条**（65.9%）。顶层评论里 23.9% 是 0 赞，与既有实测一致：热度前段的尾部已开始出现附和与复制。 我推断

> **三条取样偏差，必须写在读之前。**第一，样本按热度取，所以下面的分布是「**热度样本内**的分布」，不是全站分布。第二，点赞随时间累积，早期评论天然占优——本片才 27 小时，这个偏差比成熟视频更大。第三，楼中楼只抓到每楼前 3 条，但争议度用的是全量真实回复数。

普遍度＝该簇条数 ÷ 有效样本 58（在问：多少人**提到**）

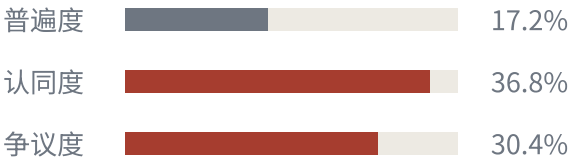
认同度＝该簇点赞合计 ÷ 顶层点赞合计 4,554（在问：多少人**认同**）

争议度＝该簇楼中楼回复合计 ÷ 顶层回复合计 240（在问：多少人**愿意为它争**）

三个轴不可通约，因此不做加权合成——合成需要权重，没有理由的权重就是伪精度。

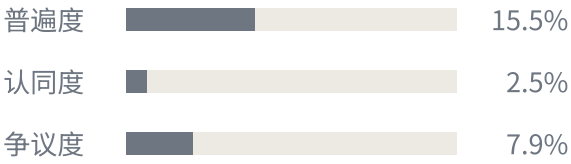
3.2 观点谱

Claude 缺席与账号被封 10 条



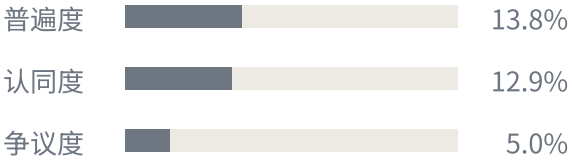
主战场：认同与争议双高，全站最高赞的信息藏在楼中楼

测的是模型还是 harness 9 条



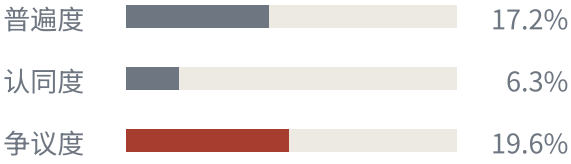
被围攻：认同度倒数第二，却是唯一有方法论价值的簇

成本・额度・使用门槛 8 条



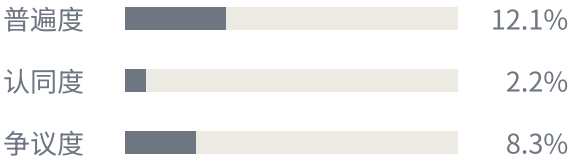
共识区：点头的多，辩的少

逐个工具的点名体验 10 条



次战场：Kimi 与 DeepSeek 是主要挨打对象

按场景分工・组合使用 7 条



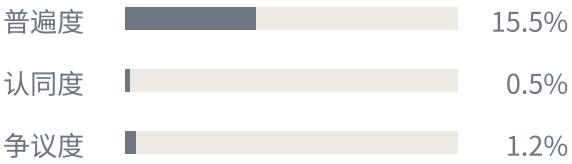
分歧带：说法都对，但谁也没说服谁

结论速览与「谁最强」 5 条



边缘：省流党的自留地

缺席名单与商单质疑 9 条



边缘：问的人不少，没人为它辩护

怎么读：每个方格是一类观点，三行分别是三个轴；条形统一按 40% 满刻度绘制，便于跨簇比较，右侧数字是该轴的真实占比。**口径**：仅统计 88 条顶层评论（楼中楼无 rcount），有效样本 58 条；认同度以顶层点赞 4,554 为分母，争议度以顶层回复 240 为分母。

3.3 三条反常发现

一、全站最高赞的那句话，不在顶层评论里。顶层第一高赞是 758 赞的「没有Claude的原因 be like:」，一句没有任何信息量的引子。真正的答案在它的楼中楼里——UP 主本人回复「小克还没测完，号封了」，1,927 赞，是顶层第一名的 2.5 倍。热度排序把全片最关键的补丁埋在了第二层。 评论说

二、认同度与信息量成反比，这次尤其极端。「测的是模型还是 harness」这一簇，普遍度排并列第一（15.5%），认同度只有 2.5%——全场倒数第二。而零信息的「其实」「[微笑]」这类水帖合计拿走了 34.1% 的点赞。**热度奖励的是「短、狠、能表态」，惩罚的是「长、要条件、读完还不能一句话反驳」。** 我推断

三、最有分量的一条经验，藏在最不起眼的楼中楼。一条 44 赞的回复说「Workbuddy 调用最多的是 DS，因为便宜量大」。如果成立（无人核实），**同一个底层模型，在 WorkBuddy 里排第 2，在 DeepSeek 自家产品里排第 6。**那这份榜单测的到底是什么，答案就自己浮出来了。 评论说 我推断

04

评论区核心总结

逐簇展开，按内容密度排序，不按数据大小排序

4.1 控制变量之问：你测的是模型，还是 harness

结论先行：这是全场唯一触及方法论要害的一簇，也是认同度倒数第二的一簇。 我推断

他们的论证分三层，一层比一层具体： 评论说

> 似乎对 deepseek harness 不太公平，dsh 是一个裸 runtime，他的核心是自定义插件系统。而 workbuddy、豆包等已经内置了大量工程优化。只能说对于有工程能力的人来说，dsh 的生态位在最高一档。对于 AI 小白来说，dsh 没有实用价值。
>
> @码农阿禹 · 32 赞 · 4 条回复

第一层是「不公平」：DeepSeek Harness 是裸 runtime，其余几家是成品 Agent，等于让一个人光脚和别人穿鞋跑。第二层是「测错了对象」：「比的啥，大模型还是 harness？还是各种组合，控制变量呢」——这条 11 赞。第三层最狠，直接指向概念混乱：「还有评论区一堆分不清模型和框架的给我看力竭了，科普类视频前面应该先把概念申明清楚」——7 赞，0 回复，没人接。

与视频的对照：视频在 00:00 问的是「六个 AI 工具谁最强」，在 07:06 才承认「主实验中别的对象均为各大 Agent 的默认模式」。**它知道问题在哪，但只放在片尾的一句免责里**。这一簇的批评成立，且比视频自己的免责更准确：不只是一次实验测不了「模型能力」，而是这次实验连「Agent 产品能力」都测不准——因为六家的默认档并不同质。 **我推断**

4.2 Claude 为什么不在榜上：一个由 UP 主自己补的洞

结论先行：这不是评论区的猜测，是事实，且由 UP 主亲口确认——**测到一半账号被封**。 **评论说**

问题的热度远超其他任何话题：顶层前十里四条都在问「克老师去哪了」（「没有Claude的原因be like」758 赞、「怎么没有我们克老师」364 赞 46 回复、「猜猜少了谁」236 赞、「我要点名一家 A 开头的公司」202 赞）。而答案只出现了一次，在 758 赞那条的楼中楼：「**小克还没测完，号封了**」——**1,927 赞**。

这条回复带出的连锁反应比它本身更有意思。评论区迅速分成两拨：一拨把它当成 Claude 依旧最强的证据（「那感觉 claude 登顶了，gpt 和 claude 感觉是 87 分和 95 分的区别」），另一拨当成 Claude 已经不行了的证据（「谁是第一不重要，claude 是真拉完了」「工作的话 Claude 目前还是遥遥领先」——这两条互相矛盾，却都拿到了赞）。 **评论说**

与视频的对照：视频里完全没有提这件事。这是一个信息缺口——**缺失的那个选手，恰好是很多人心中的默认答案**。榜单缺了 Claude，等于把「谁最强」这个问题永久悬置了。片方的处理方式（不解释、不声明）比解释更省事，也更损公信力。 我推断

4.3 真实付费体验：榜单上的「元」，和用户口袋里的「元」不是一回事

结论先行：这一簇的认同度排第三（12.9%），争议度很低（5.0%）——说明它是共识，而且是**有支付经验的人之间的共识**。 我推断

评论区给出的真实价格结构，比视频的成本列具体得多：WorkBuddy「每天 100 积分，逢年过节还送个大几百一千，基本用不完」（57 赞）；豆包 2.1 Pro「只跑了 8 道题就把一周额度用完了」（这是片方自己说的）；Qoder「给我做了两个 PPT 一共就 20 来页，中档 150 多块钱的 credits 干没了一半」（0 赞，但信息密度最高）。 评论说

还有一条把「贵」的另一种形态点了出来：「最强 ai 工具是不要钱的实习生，因为实习生会自费买 ai 工具」——571 赞，全场第二。它是个段子，但它说的是一件事：**在真实工作流里，「成本」从来不只等于 API 账单**，还包括订阅、额度、翻墙、验证码、账号风险。 评论说

与视频的对照：视频把成本压成了一个数（¥），评论区把它拆回了四种形态（积分／额度／按量／订阅），还额外加了「账号会不会被封」这一项。后者是这份榜单完全没有度量的隐性成本，而它刚刚让一个选手退赛。 我推断

4.4 挨打名单：Kimi、DeepSeek、豆包各自的差评形状不同

结论先行：这一簇争议度排第二（19.6%），但差评的性质完全不同——Kimi 被骂「性价比」，DeepSeek 被骂「稳定性」，豆包被骂「能力」。

对象	代表性差评	差评的性质
Kimi	「Kimi 真的是拉完了，卡、慢、贵全占完了，算力比不上 gpt，价格比肩 Claude」	性价比问题，与榜单第 4 名、¥24.63 吻合

对象	代表性差评	差评的性质
DeepSeek	「我昨天着急用 deepseek，但显示服务器重试，所以 deepseek 最菜。真没带情绪啊，绝对没带」（59 赞，12 回复）；「deepseek 昨天告诉我，做漫剧的占用了它 60% 算力，内存崩了」	可用性问题，不是能力问题
豆包	「可怜的豆包天天被跟奶蛙拴在一起」；另有实测「我用围棋测试过这几个，赢到最后的是豆包，但最 sb 的是 kimi，每次下二十手就直接投降」	口碑问题，与榜单第 3 名不矛盾

与视频的对照：视频只测「一次性任务完成度」，评论区补的是「反复使用时的体验」。这两个维度会给出不同的排名——DeepSeek 在片子里输在「想太久还想错」，在评论区输在「关键时刻连不上」。**后者对日常使用的杀伤力更大，但它无法被一次性实验测出来。** 我推断

4.5 省流党与分工派：两种都不算错的读法

结论先行：这两簇加起来只有 12 条，却是评论区的「实际结论」——大多数人读完并没有记住 87.37 或 92.56，记住的是「GPT 拉满」和「按场景分工」。 我推断

省流派：「省流：gpt6 Astra ultra」（116 赞）、「省流 GPT6 拉满，解决你所有问题，除了钱的问题」（86 赞）。分工派：「事实是所有一起用，针对工作流的不同子任务安排不同 ai」（19 赞）、「vibe coding claude 是天，其它无脑 gpt」（43 赞）、「作为技术人，有 claude 选 Claude，没有选 qoder」（22 赞）。 评论说

与视频的对照：视频用一张榜回答了「谁第一」，评论区用一句话否掉了这个问题——「**第一」在真实工作流里不存在，只有「这个子任务用谁」**。这也解释了为什么 WorkBuddy 拿了第 2 却没人讨论它：**它赢在「每元得分」，而这种赢法不产生故事。** 我推断

4.6 缺席名单与商单质疑：问的人多，辩护的人为零

结论先行：这是认同度最低的一簇（0.5%），不是因为它错，而是因为它是「提问」而不是「主张」——提问不需要别人点赞。 我推断

被点名的缺席者：Gemini（「Gemini4 和 gork 呢」）、Grok、GLM（「为什么没有 GLM 啊」）、腾讯元宝（「腾讯元宝怎么说」）、Trae（「trae 呢？？？」）、Coze（「coze 跟这些是啥关系」）。加上 Claude，**这份「六大」名单至少漏掉了五个在中文用户里有人用的选项。**

评论说

商单质疑只有两条，且都没展开：「盲猜是 workbuddy 商单」（9 赞）、「没有推广谁投的流？」（1 赞）。**没有找到任何证据支持这个猜测**，片方在简介和片头都做了否认，且榜单第 1 名并不是 WorkBuddy——如果要做商单，这个排法并不聪明。 我推断

> **一条利益相关的声明。**本报告由运行在 WorkBuddy 中的助手生成，而本次榜单的第 2 名正是 WorkBuddy。上面所有关于它的判断都基于片内数字与评论区原文，但没有第三方复核；**读者对这一节可以自行打折。**

05

关键参数与对照时间点

速查层：所有能抄走的数字

5.1 六家总账

参数	数值	口径与陷阱
满分	宣称 100，实际 **97**	办公 73.5 + 代码 23.5；所有分数应按 97 分制理解
题量	20 题	来源为 6 个公开 bench 精选；题量少，片方自认
能力维度	5 类	表格 3、数据分析 3、PPT 1、检索 2、网页 3（据片中题号反推）

参数	数值	口径与陷阱
重复次数	「多次独立重复」	未公布具体次数，也未公布如何取平均
成本列	¥0.97 – ¥24.63	**最大陷阱**：混用积分、额度百分比、按量、点数折算，汇率未公开
耗时列	7.3 – 34.7 分钟	仅网页分项表给出；总榜未列耗时
对话记忆	「尽可能隔离」	未说明隔离方式，跨题污染无法排除

5.2 档位倒挂的两个样本

对比项	WORKBUDDY	豆包	读法
低档成本	¥0.97	¥0.66	两家低档都在 1 元以内
高档成本	¥28.66	¥13.99	高档是低档的 21–30 倍
成本倍数	29.5×	21.2×	片方口播说「30 倍」，量级无误
分数变化	87.37 → 80.68	26.08 → 22.29	两家高档都更差
触发原因	一道检索题想太久想错	额度耗尽，只跑完 8 题	机制不同，结论同向

5.3 对照时间点

时间	内容	为什么要看这一处
00:37	试卷设计：6 个 bench、20 道题	「比学术界不足，比自媒体界有余」的自我定档在这
01:05	总榜与满分脚注	73.5 + 23.5 = 97 的缺口在这一帧

时间	内容	为什么要看这一处
01:59	WorkBuddy 档位对照表	87.37 / ¥0.97 与 80.68 / ¥28.66 同屏
02:28	豆包档位对照 + 额度说明	「2.1 Pro 只跑 8 题就用完一周额度」
03:24	表格三题得分表	6 家几乎全满分，唯一失分是豆包 3.92
03:54	数据分析陷阱题	123 + 21 = 144 条的推理链，全片设计最好的一题
05:15	PPT 六家成品并排	差距在排版细节，不在能力
06:07	网页题：读 Excel	豆包上传 Excel 解析失败，是唯一硬故障
06:37	网页能力排名表	「花费」列单位混乱的证据在这一帧
07:06	局限性自述	片方自己承认只测了默认档

06

内容纠偏

速查层：哪些数字不能直接引

6.1 字幕来源：本片无官方字幕，本报告的底稿是本地转写

B站侧未提供可用字幕，因此本报告用本机 faster-whisper（large-v3，float16，BatchedInferencePipeline）自行转写，7.7 分钟音频耗时 26.6 秒（17.3× 实时）。**这意味着逐字稿本身不可作为引用**——它是机器转写，不是 UP 主文本。 我推断

但本报告的**所有数字都不依赖转写**：榜单、成本、档位、分项得分均从 1080p 原片画面逐帧读出（抽帧核对），因此数字可靠性高于逐字稿。这一点与多数同版权威性判断相反，值得说明。

6.2 转写误转清单

转写结果	实际应为	危害
DeepSeek 哈密斯／Hardness／Harmony	**DeepSeek Harness**	同一产品名出现三种错法，其中「Harmony」会让人误以为是一个新模型，直接毁掉 4.4 那一节的论点
末期腾讯夫	**莫欺腾讯富**	原句是「三十年河东，三十年河西，莫欺腾讯富」，转写后语义完全丢失
机关算尽太聪明，反悟了青青性命	机关算尽太聪明，反误了卿卿性命	《红楼梦》原句，转写后不像引用
一箭轻松手段	（语义应为「都能轻松搞定」一类）	无法还原准确措辞，本报告未引用此句
视觉中的简单体	试题中的简单题	轻微，不影响理解

6.3 视频自身的不自洽

这一类比转写错误值钱，共三处：

其一，满分对不上。榜单标题写「Zhanbench 排行榜（满分 100 分）」，脚注写「办公题满分 73.5、代码题满分 23.5」。**73.5 + 23.5 = 97**。所有展示的分数（92.56、87.37……）都是 97 分制下的实得分，直接当成百分制会让读者高估整体水平约 3 分。**视频说** 01:05

其二，DeepSeek 那题的两个口径打架。口播说「思考了整整 43 分钟，烧了 16 块钱」；同段落贴片上的烧字写「总用时为 115 分钟，总花费 20.8 元，等于此题占用了 40% 的总时间和 80% 的总成本」。**43 与 115、16 与 20.8 对不上**，最可能的解释是前者为单次运行、后者为多次重复合计——但片中没有说明。**这一处我没有核实到确切口径**，引用时应两个数都带上。**视频说** 02:56

其三，成本列的单位不统一。网页能力排名表的「花费」列同屏出现四种单位：千问「46.8 积分」、WorkBuddy「13.0 积分」、Kimi「4.23% 月额度」、Codex「5 点 5 小时额度」、豆包「13.3 额度」、DeepSeek「¥1.12 按量」。随后统一折成「¥0.36 / ¥0.13 / ¥1.66 / ¥0.25 / ¥0.11 / ¥1.12」。**折算汇率没有公开**，而这一列正是「越贵越菜」这条主张的支点。**视频说** 06:37

6.4 纠偏结论

可以放心引用的：各家的过关题数、办公／代码分项分、档位对照的成本倍数与分数变化、表格与网页的分项得分。**需要加限定的**：任何关于「贵」的结论——因为它是折算价，不是账单。**不能引用的**：「满分 100」。

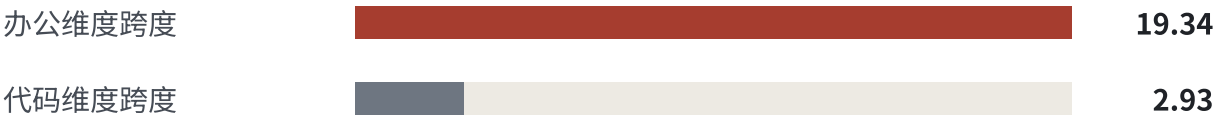
07

延伸发散

这份榜单能用到什么程度，以及它没说的那件事

7.1 被总分榜埋掉的一个数：差距几乎全在「办公」，不在「代码」

把六家的两个分项摊开算跨度：**办公维度从 54.59 到 73.93，跨度 19.34 分；代码维度从 16.33 到 19.26，跨度只有 2.93 分。**换句话说，**六家的代码能力差不到 3 分，办公能力差 19 分**——差了 6.6 倍。 我推断



怎么读：条形长度＝该维度内最高分与最低分之差（满分分别为 73.5 与 23.5）。**口径**：取六家榜单原始分项分，未做归一化；两个维度的满分不同，所以看的是「差距占满分的比例」——办公 26.3%，代码 12.5%。

这个发现会改写标题：**不是「越贵的 AI 越菜」，而是「越贵的 AI 在办公场景里不一定更强，在写代码上大家本来就差不多」**。这也解释了为什么千问和 DeepSeek 的代码分（19.26、19.11）反而高过 Codex（18.63），总分却被办公分拖到第 5、第 6。

7.2 「每元得分」才是这份数据真正能用来做决策的指标

用视频自己的成本列算：WorkBuddy 90.07 分／元、千问 55.46、豆包 54.76、Codex 40.96、DeepSeek 3.54、Kimi 3.19。**头尾差 28 倍**。但请连着 6.3 一起读——分母是折算价，这个指标的精度不会高于分母。 我推断

它真正有用的地方不在绝对值，在**排序的稳定性**：即使成本列有 ±50% 的误差，WorkBuddy、千问、豆包 / Codex 这一档与 Kimi、DeepSeek 那一档之间的断层也不会消失。断层来自计费模式，不来自测量误差。

7.3 Harness 才是这轮竞争的护城河，模型不是

把三条线索并起来看：评论区说「WorkBuddy 调用最多的是 DS」；WorkBuddy 排第 2、DeepSeek 自家排第 6；评论区反复说「dsh 是裸 runtime，靠插件生态」被「内置大量工程优化的成品」打败。**如果这些都成立，那么这次横评测出的最大变量不是模型，是外围工程。** 评论说 我推断

这个判断有个可检验的推论：**同一个模型，换一个 harness，分数应该有明显位移**。UP 主自己在片尾说要加「同 Agent 不同模型／同 AI 不同 Agent」的对照——那正是这个实验真正的下一步，也是这份榜单最该补的一格。

7.4 为什么「贵的一定更好」这个直觉会失效

不是因为贵的模型笨，而是因为「贵」**在这类产品里买到的东西，和「答对题」不是同一种东西**。高档位买到的是更长的思考链、更多的自我校验、更多的工具调用轮次。这些在「有唯一正确答案、且答案可被检索」的题上，收益递减得极快；在「开放、需要判断」的任务上才开始回本。而这份试卷 20 道题里，绝大多数是前者。 我推断

所以正确读法是：**高档位不是没用，是它服务的是另一类任务**。拿这份卷子去否定高档位，等于拿短跑成绩否定举重选手。

7.5 还没解决的，和可以继续挖的

4 项　这份报告没有解决的问题

一、**成本口径**。各家的积分、额度、点数到底怎么折成元，片中没有公开，评论区也没有人能算出来。这一项不解决，「越贵越菜」就永远只是半个结论。

二、**DeepSeek 那题的两个口径**。43 分钟／16 元 与 115 分钟／20.8 元 的关系没有核实到。可能是单次与合计，但没有证据。

三、**Claude 的真实位置**。账号被封导致退赛，没有替代测试（例如换 API 通道）。这意味着榜单永远缺了最有争议的那一格。

四、**「多次独立重复」到底几次**。方差没有公布，单次异常的权重无法评估——而 DeepSeek 那道题单次就跑了 43 分钟，恰好是最可能被单次异常放大的情形。

要不要接到你自己身上。如果你想用这份榜单做自己的选型，缺的从来不是这张表，而是三件事：**你的任务是哪一类**（表格／检索／网页，还是开放判断）、**你的计费方式是哪种**（按量还是订阅，差别可以到 20 倍）、**你能不能接受账号风险**。把这三件事说清楚，这份榜单就能被切成只属于你的那一列——那是另一次追问能做的事，不适合塞进一份要对外分享的报告里。

一句话最终建议。把它当「档位溢价」的证据读，不要当「谁最强」的结论用——它最扎实的那一页是 WorkBuddy 快速与极致+MAX 的同屏对照，最不可靠的那一页是成本列。

生成于 2026-10-17 · 数据源：B站公开接口（视频元数据、150 条评论）+ 本机 faster-whisper 转写 + 1080p 原片抽帧核对 · 引文中括号内的 B站表情代码已剔除

本报告不含任何读者个人信息，可自由分享。